

Klasifikasi Sampah Menggunakan MobileNetV2

Tim Mahasiswa:

1. Felix Stevanus / 2702252090
 2. Hanzel Octavian Lesmana / 2702241162
 3. Richard Chrysander / 2702242972
-

I. Introduction (Pendahuluan)

1.1. Latar Belakang:

Permasalahan pengelolaan sampah saat ini merupakan isu global yang terus meningkat seiring dengan pertumbuhan populasi yang meningkat, perkembangan industri dan konsumsi masyarakat yang tidak terkendalikan. Volume sampah yang dihasilkan setiap harinya makin bertambah, sementara kemampuan untuk mengelola ulang sampah masih sangat terbatas. Salah satu tahapan yang penting dalam proses pengelolaan sampah adalah proses pemilahan sampah berdasarkan jenis material, seperti kertas, plastik, logam, dan kaca. Pemilahan yang tidak baik dapat menyebabkan penurunan kualitas dalam proses daur ulang dan nantinya akan mencemari lingkungan itu sendiri.

Saat ini banyak negara berkembang, proses pemilahan sampah masih dilakukan secara manual. Metode ini dianggap memiliki kelemahan seperti membutuhkan tenaga kerja yang besar, biaya operasional yang tinggi, hingga tingkat kesalahan manusia yang relatif tinggi. Oleh karena itu, dibutuhkan model berbasis teknologi yang dapat menyelesaikan dalam proses pemilahan sampah yang akurat, efisien, dan mudah digunakan.

Perkembangan teknologi kecerdasan buatan, khususnya deep learning sendiri sangat berpotensi dalam menyelesaikan kasus tersebut. Khususnya pada bidang computer vision, Convolutional Neural Network (CNN) telah teruji dan terbukti dapat mengenali pola visual secara efektif dan dapat digunakan secara luas dalam aplikasi seperti pengenalan wajah, deteksi objek, dan klasifikasi citra. Dengan memanfaatkan CNN (Convolutional Neural Network), sistem akan dapat dilatih untuk mengenali karakteristik visual dari berbagai jenis sampah.

Dalam kasus ini, kami menggunakan arsitektur MobileNetV2 yang

merupakan model CNN yang ringan dan efisien. MobileNetV2 sendiri dirancang untuk kebutuhan dengan komputasi yang rendah namun tetap memberikan performa yang baik. Hal ini menjadikan MobileNetV2 sesuai dengan apa yang kami butuhkan yaitu, nantinya model dapat diaplikasikan secara nyata dan dapat dijalankan pada perangkat dengan keterbatasan sumber daya, seperti perangkat mobile.

Tujuan utama projek ini adalah membangun suatu model klasifikasi sampah berbasis citra digital menggunakan MobileNetV2 dan dataset dari kaggle. Model yang kami buat diharapkan dapat mengklasifikasi sampah ke dalam dua belas kategori, yaitu cardboard, metal, paper, plastic, trash, battery, biological, brown-glass, clothes, green-glass, shoes, white-glass. Dalam proyek ini kami juga akan melihat dahulu dataset sebelum kami proses lebih jauh.

1.2. Tujuan:

Tujuan utama penelitian ini adalah mengembangkan model klasifikasi sampah berbasis citra digital menggunakan metode deep learning CNN(Convolutional Neural Network dengan arsitektur MobileNetV2, Model yang dikembangkan diharapkan dapat menjadi model klasifikasi sampah yang bagus berdasarkan karakteristik visualnya dan dapat membantu dalam proses pemilahan sampah manual yang selama ini masih banyak digunakan.

Selain itu, penelitian ini bertujuan untuk mengimplementasikan arsitektur MobileNetV2 sebagai model klasifikasi citra yang ringan dan efisien, namun dengan tetap memperhatikan kemampuan dalam menghasilkan akurasi yang baik dengan kebutuhan komputasi yang rendah.

Selain itu, penelitian ini bertujuan untuk menggunakan dan menganalisis dataset klasifikasi sampah yang diperoleh dari kaggle, dan disini dilakukan analisa dataset dari bagaimana karakteristik datanya , keseimbangan jumlah citra, variasi ukuran citra dan kualitas, serta memastikan bahwa dengan adanya ketidakseimbangan data model akan berjalan sesuai yang diharapkan.

Model yang dikembangkan juga diharapkan dapat mengklasifikasikan sampah ke dalam dua belas kategori, yaitu cardboard, metal, paper, plastic, trash, battery, biological, brown-glass, clothes, green-glass, shoes, dan white-glass. dan yang tidak kalah penting yaitu akan dilakukan evaluasi

model dengan metrik akurasi, precision, recall, dan confusion matrix. hal ini dilakukan agar dapat melihat lebih dalam seberapa model dapat mengklasifikasi sampah dengan baik.

1.3. Ruang Lingkup:

Proses penelitian dimulai dari eksplorasi dan pemahaman dataset, dilanjutkan dengan tahap preprocessing data untuk meningkatkan kualitas input model. Selanjutnya dilakukan pelatihan model klasifikasi menggunakan arsitektur MobileNetV2 dengan pendekatan transfer learning, serta evaluasi performa model menggunakan metrik evaluasi yang relevan. Model yang telah dilatih lalu dideploy ke dalam sebuah aplikasi web menggunakan Streamlit, sehingga pengguna dapat mengunggah citra sampah dan memperoleh hasil prediksi beserta tingkat confidencenya.

II. Dataset

2.1. Data Explanation:

Dataset terdiri dari cardboard, metal, paper, plastic, trash, battery, biological, brown-glass, clothes, green-glass, shoes, white-glass. Setiap citra memiliki resolusi dan kondisi pencahayaan yang berbeda dan bervariasi, sehingga lumayan mencerminkan kondisi yang ada di lapangan nantinya. Struktur data disusun dalam bentuk folder, dimana setiap folder berisi satu kelas. hal ini mempermudah kita dalam proses pengambilan dataset.

Sumber:

<https://www.kaggle.com/datasets/mostafaabla/garbage-classification>

2.2. Eksplorasi (EDA):

Dataset terdiri dari 12 kelas dengan total 15515 citra. Distribusi kelas tersebut menunjukkan adanya ketidakseimbangan data, sehingga perlu dilakukan oversampling untuk data dengan citra berjumlah kecil, dan undersampling untuk data dengan citra berjumlah besar. Teknik oversampling dan undersampling tidak dilakukan dengan terlalu ekstrim

untuk preservasi data yang baik, karena perbedaan antar datanya terlalu besar. Untuk bisa mengatasi hasil akhir yang masih tidak seimbang, perlu dilakukan class-weight supaya model dapat melakukan training dengan lebih efisien.

Dataset memiliki ukuran gambar yang bervariasi, dengan aspect ratio yang juga bervariasi, sehingga harus dilakukan resizing ke size 224x224 dengan padding untuk menghasilkan aspect ratio yang sama tanpa melakukan stretching. Selain itu, berdasarkan inspeksi secara visual, terdapat variasi pencahayaan dan latar belakang, sehingga data augmentation seperti rotasi, random zoom, dan brightness adjustment diperlukan. Data augmentation lain untuk meningkatkan robustness juga bisa diimplementasikan. Terakhir, perlu dilakukan konversi mode warna menjadi RGB karena terdapat variasi mode warna pada data.

III. Modeling (Pemodelan)

3.1. Arsitektur Model:

3.1.1 Pemilihan Arsitektur

Pemilihan MobileNetV2 sebagai arsitektur utama karena pertimbangan efisiensi dan performa. MobileNetV2 menggunakan konsep depthwise separable convolutional dan inverted residual block yang mampu mengurangi jumlah parameter tanpa mengorbankan akurasi secara signifikan.

3.1.2 Transfer Learning

Pendekatan transfer learning diterapkan dengan memanfaatkan bobot pre-trained MobileNetV2 yang telah dilatih sebelumnya menggunakan dataset ImageNet. Maka hal ini, model tidak perlu belajar dari awal lagi, maka dari itu kami hanya menyesuaikan lapisan akhir untuk klasifikasi sampah.

Lapisan awal MobileNetV2 dibekukan (freeze) untuk mempertahankan fitur visual umum, sementara lapisan klasifikasi baru ditambahkan dan dilatih menggunakan dataset sampah.

3.1.3 Arsitektur Model

Arsitektur akhir model terdiri dari MobileNetV2 sebagai feature extractor, diikuti oleh Global Average Pooling layer, Dense layer dengan aktivasi ReLU, Dropout layer untuk regularisasi, serta output layer dengan aktivasi Softmax untuk klasifikasi multi-kelas.


3.2. Skenario Pelatihan:

Proses pelatihan dilakukan dengan konfigurasi sebagai berikut:

- Ukuran input: 224×224 piksel
- Optimizer: Adam
- Learning rate: 0.0001
- Loss function: Categorical Crossentropy
- Batch size: 64
- Epoch: 30

Data augmentation seperti rotasi, flipping, dan zooming diterapkan untuk meningkatkan kemampuan generalisasi model.

3.3. Diagram Arsitektur:



IV. Evaluation (Evaluasi)

4.1. Metrik Evaluasi:




Classification Report				
	precision	recall	f1-score	support
battery	0.9891	0.9479	0.9681	96
biological	0.9787	0.9684	0.9735	95
brown-glass	0.8814	0.8525	0.8667	61
cardboard	0.8929	0.9259	0.9091	81
clothes	0.9344	0.9828	0.9580	116
green-glass	0.9836	0.8333	0.9023	72
metal	0.8119	0.9318	0.8677	88
paper	0.9619	0.8860	0.9224	114
plastic	0.8406	0.6744	0.7484	86
shoes	0.9780	0.9780	0.9780	91
trash	0.8772	0.9615	0.9174	52
white-glass	0.7079	0.8750	0.7826	72
accuracy			0.9053	1024
macro avg	0.9031	0.9015	0.8995	1024
weighted avg	0.9104	0.9053	0.9052	1024

Hasil dari classification matrix sendiri menunjukkan bahwa model memiliki kinerja yang sangat baik dengan akurasi mencapai 90,53%, Sebagian besar kelas seperti battery cardboard, metal, dan shoes memperoleh nilai precision, recall, dan F1-score di atas 0.95, hal ini menandakan bahwa kemampuan klasifikasi yang singkat akurat dan konsisten. Nilai macro average F1-score sebesar 0,8995, menunjukan performa yang relatif seimbang pada semua kelas, sedangkan jika kita lihat pada weighted average F1-score sebesar 0,9052 hal ini baik karena model tetap stabil dengan adanya perbedaan data tiap kelas.

4.2. Comparison (Perbandingan):

Sebelumnya, kami mencoba untuk melakukan training tanpa melakukan fine tuning, dan mendapatkan hasil f1-score 0.83, yang sudah cukup memuaskan. Namun, untuk meningkatkan performa model, dilakukan fine tuning dengan mengubah learning rate $1e-5$ menjadi $1e-4$, dan epoch dari 10 menjadi 30, serta menerapkan early stopping untuk mengoptimalkan hasil training. Setelah dilakukan fine tuning, model dapat memberikan hasil f1-score di angka 0.9, yang menunjukkan keberhasilan dalam meningkatkan performa model.

4.3. Visualisasi Hasil:



Berdasarkan visualisasi hasil yang sudah kami lakukan, dapat dilihat bahwa training dan validation accuracy model setiap epochnya menunjukkan perkembangan. Selain accuracy, bisa dilihat juga bahwa lossnya selalu menurun setiap epochnya. Ini menunjukkan bahwa model berhasil belajar dengan efektif. Di confusion matrix, bisa dilihat bahwa model paling sering

bingung untuk membedakan antara plastic dan white glass, dikarenakan kemiripan karakteristik antar kedua jenis sampah tersebut.

V. Deployment (Implementasi)

5.1. Aplikasi:

Deployment trash classification kami deploy secara local menggunakan Streamlit. Kita memilih streamlit karena streamlit bisa membuat sebuah UI sederhana yang mudah diintegrasikan dengan tensorflow serta py file.

Di web streamlit, kita dapat mengupload gambar pada tempat file uploader yang tersedia. Gambar yang sudah diupload kemudian akan di preprocess sesuai dengan alur preprocess (format RGB, resize 224x224, normalisasi dengan function preprocess_input) pada saat training model agar karakteristiknya sesuai. Setelah preprocessing selesai, gambar dikirim ke model untuk dilakukan prediksi. Jika sudah akan dikeluarkan hasil prediksi yang berupa class sampah dan nilai confidencenya. Web ini mendukung 12 jenis sampah, sesuai dengan yang kita gunakan untuk training model (battery, biological, brown glass, cardboard, clothes, green glass, metal, paper, plastic, shoes, trash, dan white glass).

5.2. Alur Kerja:

Web streamlit menerima gambar yang diupload oleh user kemudian dilakukan preprocessing seperti konversi ke RGB, resize 224x224, dan normalisasi menggunakan function preprocess_input. Setelah itu kita load model dari file .keras untuk memprediksi gambar yang tadi sudah diupload. Model menghasilkan probabilitas untuk setiap class sampah, kemudian aplikasi menentukan class dengan nilai probabilitas tertinggi sebagai hasil prediksi dan menampilkan class beserta nilai confidence.

VI. Reflection (Refleksi)

6.1. Analisis Kritis:

Pendekatan Deep Learning melalui model MobileNetV2 sudah cukup sesuai, karena model tersebut memiliki kemampuan ekstraksi fitur visual yang baik, seperti tekstur, bentuk, dan pola warna yang penting dalam membedakan jenis sampah. Selain itu, dengan penggunaan transfer learning, model dapat memanfaatkan fitur umum dengan lebih baik sehingga pelatihan dapat dilakukan dengan efisien. MobileNetV2 juga

dirancang sebagai model yang efisien dalam komputasi, sehingga dapat melakukan inferensi dengan waktu respons yang relatif cepat tanpa memerlukan hardware dengan spesifikasi yang tinggi, namun tetap memberikan hasil yang memuaskan.

Pendekatan ini masih memiliki beberapa keterbatasan, seperti adanya sensitivitas terhadap variasi background. Objek sampah seringkali berada pada latar belakang yang sangat bervariasi, sehingga pada implementasi nyata, akurasi model dapat berkurang. Model juga memiliki pendekatan klasifikasi tunggal, dimana model mengasumsikan hanya ada satu objek utama dalam satu gambar. Pada kondisi nyata, satu gambar dapat mengandung beberapa jenis sampah sekaligus, yang tidak dapat ditangani secara optimal oleh pendekatan klasifikasi.

6.2. Kendala & Pembelajaran:

Selama pembuatan project kendala yang kita hadapi hanya sedikit, namun kita mengalami kendala berupa rendahnya akurasi dan confidence pada saat testing prediksi model, bahkan saat kita menguji menggunakan gambar yang ada di dataset pelatihan. Masalah ini awalnya sulit diidentifikasi karena hasil metrik seperti akurasi dan loss menunjukkan hasil yang cukup baik. Setelah dilakukan penelusuran lebih lanjut, ditemukan bahwa penyebab utama berasal dari kesalahan pada tahap fine tuning model, yaitu penggunaan parameter `training=True` pada `(x = base_model(inputs, training=True))`. Pengaturan ini menyebabkan lapisan Batch Normalization terus memperbarui statistiknya selama proses inferensi, sehingga fitur yang dihasilkan menjadi tidak stabil. Solusi yang diterapkan adalah menghilangkan parameter tersebut sehingga model dapat menghasilkan prediksi yang konsisten serta akurat.

VII. References (Referensi)

[1] M. Abadi *et al.*, “TensorFlow: A system for large-scale machine learning,” in *Proceedings of the 12th USENIX Symposium on Operating Systems Design and Implementation (OSDI)*, Savannah, GA, USA, 2016, pp. 265–283.

[2] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, NV, USA, 2016, pp. 770–778.

[3] F. Chollet, *Deep Learning with Python*, 2nd ed. Shelter Island, NY, USA: Manning Publications, 2021.

VIII. LAMPIRAN

Screenshot Aplikasi



GitHub:

<https://github.com/SalmonFisherman/TrashClassificationFinalProject>

Demo:

<https://drive.google.com/file/d/1LZDrTTjQGX6ukt3WreRHxiDp9T6Kh2C4/view?usp=drivesdk>

Presentation:

<https://drive.google.com/drive/folders/1kSK1xWu7azgHYw6EnOPtEfrJGmaVX1r5?usp=sharing>

PPT:

https://www.canva.com/design/DAG7ffZiBOA/aHkx1h6sSB592je0m6TFxg/view?utm_content=DAG7ffZiBOA&utm_campaign=designshare&utm_medium=link2&utm_source=uniqueLinks&utm_id=hfb018411fc